

Лекция 6: Optical Flow

Оптический поток (Optical Flow) - фундаментальный метод анализа динамики изображений в компьютерном зрении. Он позволяет оценивать векторное поле скорости движения для каждого пикселя между последовательными кадрами видеопоследовательности. Эти данные широко используются в стабилизации видео, анализе движения, слежении за объектами, SLAM, 3D-реконструкции и медицинской визуализации.

и by Иван Копылов



Физическая суть оптического потока

1

Предположение яркостной сохранности

Базовое предположение:
интенсивность точки остается
неизменной при движении
между кадрами. $I(x, y, t) = I(x + \delta x, y + \delta y, t + \delta t)$.

2

Локальная гладкость

В малом окне изображения
оптический поток является
гладким и непрерывным.

3

Малость смещений

При малом временном
интервале между кадрами
смещения можно
аппроксимировать
дифференциальными
величинами.

Математическая модель оптического потока

1

Разложение в ряд Тейлора

$$I(x+\delta x, y+\delta y, t+\delta t) \approx I(x, y, t) + I_x \cdot \delta x + I_y \cdot \delta y + I_t \cdot \delta t$$

2

Уравнение яркостной сохранности

$$I_x \cdot \delta x + I_y \cdot \delta y + I_t \cdot \delta t = 0$$

3

Уравнение оптического потока

$$I_x \cdot u + I_y \cdot v + I_t = 0, \text{ где } u = \delta x / \delta t, v = \delta y / \delta t$$

Интерпретация уравнения оптического потока

Уравнение $I_x \cdot u + I_y \cdot v = -I_t$ можно интерпретировать следующим образом: изменение яркости в данной точке вызвано движением в направлении, параллельном градиенту интенсивности. Если градиент в точке велик, даже небольшое смещение может привести к заметной разнице в яркости.

Это соотношение является основой для построения алгоритмов вычисления оптического потока, поскольку позволяет оценивать скорость движения, исходя из измеренных пространственных и временных производных.

Основные вызовы и проблемы

Апертура

Локально возможно измерить лишь проекцию вектора скорости на направление градиента, что затрудняет определение полного направления движения.

Разрывы потока

На границах движущихся объектов наблюдаются резкие изменения, что приводит к трудностям в моделировании гладкости поля.

Шумы и нелинейности

Изменение освещения, шумы сенсоров и другие артефакты могут нарушать предположение яркостной сохранности.

Вычислительные сложности

Точное оценивание производных и решение соответствующих систем уравнений требует значительных вычислительных ресурсов, особенно при работе с высокими разрешениями.

Метод Лукаса-Канаде

Основная идея

Метод предполагает, что в небольшом окне размером $n \times n$ пикселей оптический поток (u, v) можно считать постоянным.

Математическая модель

Для каждого пикселя (x_i, y_i) в окне:
 $I_x(x_i, y_i) \cdot u + I_y(x_i, y_i) \cdot v + I_t(x_i, y_i) = 0$

Решение

Система решается методом наименьших квадратов: $(u \ v)^T = (A^T A)^{-1} A^T b$

Геометрическая интерпретация метода Лукаса-Канаде

Матрица $A^T A$ представляет собой матрицу ковариаций градиентов в окне. Если в выбранном окне интенсивность существенно меняется в разных направлениях, то матрица $A^T A$ будет невырожденной, и решение получено с высокой степенью уверенности.

В однородных областях или там, где наблюдается явление апертуры (например, вдоль края), матрица может быть вырожденной или почти вырожденной, что делает оценку u и v ненадёжной.

Ограничения метода Лукаса-Канаде

1

Размер окна

Слишком большое окно может сгладить локальные особенности, а слишком маленькое – усилить влияние шума. На практике оптимальный размер окна подбирается эмпирически.

2

Итеративное уточнение

Для случаев с большими смещениями часто используется каскад итераций. Сначала вычисляется поток в грубом приближении, затем корректируется на основе смещённых окон.

3

Адаптивное взвешивание

Некоторые реализации метода применяют взвешивание пикселей внутри окна (например, гауссовым ядром) для усиления вклада центральной области.

Пример реализации метода Лукаса-Канаде на Python

```
import cv2
import numpy as np

# Загрузка видеопотока или последовательности кадров
cap = cv2.VideoCapture("video.mp4")
ret, prev_frame = cap.read()
prev_gray = cv2.cvtColor(prev_frame, cv2.COLOR_BGR2GRAY)

# Инициализация набора точек для отслеживания
feature_params = dict(maxCorners=100, qualityLevel=0.3, minDistance=7, blockSize=7)
p0 = cv2.goodFeaturesToTrack(prev_gray, mask=None, **feature_params)

# Параметры метода Лукаса-Канаде
lk_params = dict(winSize=(15,15), maxLevel=2, criteria=(cv2.TERM_CRITERIA_EPS | cv2.TERM_CRITERIA_COUNT, 10, 0.03))

while True:
    ret, frame = cap.read()
    if not ret:
        break
    gray = cv2.cvtColor(frame, cv2.COLOR_BGR2GRAY)

    # Вычисление оптического потока для точек p0
    p1, st, err = cv2.calcOpticalFlowPyrLK(prev_gray, gray, p0, None, **lk_params)

    # Отбор точек с успешным отслеживанием
    good_new = p1[st==1]
    good_old = p0[st==1]

    # Визуализация результатов
    for i,(new,old) in enumerate(zip(good_new, good_old)):
        a, b = new.ravel()
        c, d = old.ravel()
        frame = cv2.line(frame, (a, b), (c, d), (0,255,0), 2)
        frame = cv2.circle(frame, (a, b), 5, (0,0,255), -1)

    cv2.imshow("Lucas-Kanade Optical Flow", frame)
    if cv2.waitKey(30) & 0xFF == 27:
        break

    prev_gray = gray.copy()
    p0 = good_new.reshape(-1, 1, 2)

cap.release()
cv2.destroyAllWindows()
```

В этом примере используются функции OpenCV для вычисления точечного оптического потока по Лукасу–Канаде с пирамидальным подходом. Метод успешно отслеживает движения точек между кадрами, что демонстрирует его применимость для задач слежения.

Метод Хорна-Шанка

Основная идея

Метод Хорна-Шанка является вариационным методом, который формулирует задачу оптического потока как задачу минимизации функционала энергии.

Функционал энергии

$$E(u,v) = \int \int [(I_x u + I_y v + I_t)^2 + \alpha^2 (|\nabla u|^2 + |\nabla v|^2)] dx dy$$

Компоненты функционала

Data term: $(I_x u + I_y v + I_t)^2$

Регуляризующий член: $\alpha^2 (|\nabla u|^2 + |\nabla v|^2)$

Уравнения Эйлера-Лагранжа для метода Хорна-Шанка

1

Вариация функционала

$$\delta E / \delta u = 2I_x (I_x u + I_y v + I_t) - 2\alpha^2 \Delta u = 0$$

$$\delta E / \delta v = 2I_y (I_x u + I_y v + I_t) - 2\alpha^2 \Delta v = 0$$

2

Упрощение

$$I_x (I_x u + I_y v + I_t) - \alpha^2 \Delta u = 0$$

$$I_y (I_x u + I_y v + I_t) - \alpha^2 \Delta v = 0$$

3

Интерпретация

Δu и Δv - операторы Лапласа, отвечающие за суммарное изменение функций u и v в окрестности точки.

Численная реализация метода Хорна-Шанка

Дискретизация Лапласиана

$$\Delta u(x,y) \approx u(x+1,y) + u(x-1,y) + u(x,y+1) + u(x,y-1) - 4u(x,y)$$

Итерационный процесс

$$u^{(k+1)}(x,y) = u^{(k)}(x,y) + \tau [I_x(I_x u^{(k)} + I_y v^{(k)} + I_t) - \alpha^2 \Delta u^{(k)}]$$

$$v^{(k+1)}(x,y) = v^{(k)}(x,y) + \tau [I_y(I_x u^{(k)} + I_y v^{(k)} + I_t) - \alpha^2 \Delta v^{(k)}]$$

Параметры

τ - шаг итерационного процесса

α - параметр регуляризации

Интерпретация результатов метода Хорна-Шанка

Метод Хорна-Шанка позволяет получить плотное поле оптического потока для всего изображения. Регуляризующий член обеспечивает гладкость решения, что особенно важно в областях с низким контрастом, где вычисление производных может быть шумным.

Однако сильная регуляризация (α большое) может "размывать" реальные резкие изменения потока на границах объектов, поэтому выбор параметра α является критически важным.

Пример реализации метода Хорна-Шанка

```
# Инициализация: u и v нулевыми матрицами того же размера, что и изображение
u = np.zeros_like(I_gray, dtype=np.float32)
v = np.zeros_like(I_gray, dtype=np.float32)
tau = 0.25 # шаг итераций
alpha = 15 # параметр регуляризации

for k in range(num_iterations):
    # Вычисляем производные изображения I_x, I_y, I_t (предположим, они уже вычислены)
    # Вычисляем локальный остаток
    resid = I_x * u + I_y * v + I_t
    # Вычисляем Лапласиан u и v (например, с помощью фильтра cv2.Laplacian)
    lap_u = cv2.Laplacian(u, cv2.CV_32F)
    lap_v = cv2.Laplacian(v, cv2.CV_32F)
    # Обновляем u и v
    u = u - tau * (I_x * resid - alpha**2 * lap_u)
    v = v - tau * (I_y * resid - alpha**2 * lap_v)
```

Подобная схема, при правильном выборе параметров и числа итераций, позволяет получить гладкое поле оптического потока, удовлетворяющее условию яркостной сохранности.

Сравнение методов Лукаса-Канаде и Хорна-Шанка

Метод Лукаса-Канаде


- Локальное решение
- Простота реализации
- Быстрота вычислений
- Подходит для точечного отслеживания

Метод Хорна-Шанка

- Плотное поле потока
- Регуляризация для гладкости
- Вариационный подход
- Подходит для анализа всего изображения

Вариационные методы оценки оптического потока

Вариационные методы формулируют задачу оценки оптического потока как задачу минимизации функционала энергии. Такой подход позволяет объединить данные об изменении яркости с дополнительными регуляризационными условиями, обеспечивающими гладкость и устойчивость решения.



1

Общий вид
функционала

$$E(u,v) = \int \int_{\Omega} \rho(I(x,y,t), I(x+u,y+v,t+\delta t)) dx dy + \lambda R(u,v)$$

2

Функция данных
(Data term)

Измеряет несоответствие
между значениями
интенсивности в соседних
кадрах

3

Регуляризующий член

Накладывает априорное требование гладкости на поле
оптического потока

Функция данных в вариационных методах

Квадратичная функция

$$\rho(I(x,y,t), I(x+u,y+v,t+\delta t)) = \\ [I(x+u,y+v,t+\delta t) - I(x,y,t)]^2$$

Функция Хубера

$$\rho(z) = \begin{cases} 1/2 z^2, & \text{если } |z| \leq \delta \\ \delta (|z| - 1/2\delta), & \text{если } |z| > \delta \end{cases}$$

Преимущества робастных функций

Устойчивость к выбросам и шумам в данных

Регуляризирующий член в вариационных методах

Регуляризирующий член вводится для компенсации неоднозначности (проблемы апертур) и шумов. Наиболее часто используется квадратичная функция градиентов:

$$R(u,v) = \int \int_{\Omega} (|\nabla u|^2 + |\nabla v|^2) dx dy$$

Регуляризация обеспечивает гладкость поля, уменьшая влияние локальных выбросов и способствуя устойчивому решению.

Альтернативно могут использоваться более устойчивые к выбросам нормы (например, L^1 -норма или робастные аппроксимации).

Многомасштабный (пирамидальный) подход

Построение пирамиды

Последовательное уменьшение разрешения исходного изображения:


$$I^0(x,y) \rightarrow I^1(x,y) \rightarrow \dots \rightarrow I^L(x,y)$$

Оценка потока

На каждом уровне разрешения происходит оценка оптического потока

Уточнение

$(u^{(l-1)}_0, v^{(l-1)}_0) = 2 \cdot (u^l, v^l)$, затем локальная оптимизация на уровне $l-1$



Преимущества пирамидального подхода

1

Обработка больших смещений

Грубая оценка на низком разрешении позволяет "догнать" большие движения, которые затем уточняются на более детальных уровнях.

2

Снижение вычислительной сложности

На нижних уровнях изображения имеют меньшее количество пикселей, что ускоряет вычисления.

3

Устойчивость к шуму

Грубые уровни помогают подавлять мелкие шумы, давая более стабильное начальное приближение.

Методы минимизации функционала

Метод градиентного спуска

$$u^{(k+1)} = u^{(k)} - \tau \delta E / \delta u$$

$$v^{(k+1)} = v^{(k)} - \tau \delta E / \delta v$$

Методы Ньютона и полу-Ньютона

Учитывают вторые производные функционала (гессиан) для более быстрой сходимости

Метод Левенберга-Маркуарда

$$p^{(k+1)} = p^{(k)} - [J^{AT} J + \mu I]^{-1} J^{AT} r$$

Современные подходы с глубоким обучением

Глубокое обучение предлагает альтернативный подход: вместо явного моделирования уравнений и функционалов можно обучить сверточную нейронную сеть на большом количестве размеченных данных, чтобы сеть "научилась" напрямую прогнозировать оптический поток.

1

Преимущества

Более точные и устойчивые результаты, работа в реальном времени на GPU

2

Недостатки

Требуют большого объема размеченных данных для обучения

Архитектура FlowNet

FlowNetS

Стандартная архитектура энкодер-декодер с несколькими свёрточными слоями для извлечения признаков, а затем декодер для восстановления полей u и v .

FlowNetC

Дополнительно использует корреляционный слой, который сравнивает признаки двух последовательных кадров для оценки сходства.

Особенности

Использование сверточных слоев позволяет извлекать признаки, инвариантные к смещениям и локальным изменениям.

Архитектура PWC-Net

1

Пирамидальное представление

Используется пирамидальное представление изображений для оценки оптического потока на разных масштабах.

2

Warping

На каждом уровне пирамиды происходит "сдвиг" признаков второго кадра на основе предварительной оценки потока.

3

Cost volume

Формирование корреляционного объёма для расчета сходства между признаками первого кадра и смещёнными признаками второго кадра.

Архитектура SpyNet

SpyNet – компактная модель, разработанная для оценки оптического потока с минимальным числом параметров.

1

Основная идея

Использование концепции изображений-шпионов (spying images), где входной кадр представляется в виде пирамиды.

2

Архитектура

Небольшая сеть с общим весовым набором применяется на каждом уровне пирамиды для оценки оптического потока.

3

Преимущества

Компактное представление, возможность реализации на мобильных устройствах.

Аппаратное ускорение и оптимизация

GPU ускорение


Сверточные операции выполняются значительно быстрее на GPU, что позволяет достичь обработки в реальном времени.

Сжатие модели

Применение методов квантования, pruning (удаление маловажных весов) и дистилляция знаний для уменьшения размера модели.

Легкие блоки

Использование MobileNet-блоков или других легковесных конструкций для снижения вычислительной нагрузки.



Применения оптического потока



Видеонаблюдение

Оценка направления и скорости движения позволяет обнаруживать подозрительную активность, строить траектории перемещения, а также выполнять анализ поведения.



Спортивная аналитика

Видеозаписи спортивных мероприятий обрабатываются для определения траекторий движения игроков, расчёта скоростей и анализа тактики.



Стабилизация видео

Вычисленное поле потока позволяет компенсировать неустойчивость камеры, выравнивая последовательные кадры и уменьшая эффект дрожания.

Применения в робототехнике и автономном вождении

SLAM

Оценка движения камеры относительно окружающей среды позволяет одновременно строить карту и локализовать робота или транспортное средство.

3D-реконструкция

Совместно с методами стереозрения и другими алгоритмами, оптический поток помогает восстановить глубинную информацию и пространственную структуру сцены.

Обнаружение препятствий

Анализ оптического потока позволяет выявлять движущиеся объекты и оценивать их траектории для предотвращения столкновений.


Перспективы и направления будущих исследований

Улучшение устойчивости

Разработка методов, способных адекватно оценивать оптический поток в условиях слабой освещенности или при наличии сильных шумов.

Новые типы данных

Применение методов оптического потока для анализа гиперспектральных и мультиспектральных изображений, а также видео с высоким динамическим диапазоном (HDR).



Гибридные модели

Объединение преимуществ вариационных методов и глубоких нейронных сетей для создания более интерпретируемых и устойчивых систем.

Аппаратное ускорение

Оптимизация под мобильные устройства и разработка специализированных ускорителей для реализации ключевых модулей оценки оптического потока.

Заключение

Оценка оптического потока остаётся одной из ключевых задач компьютерного зрения, позволяющей извлекать информацию о движении и динамике сцен. От классических дифференциальных методов до современных нейронных сетей – каждый подход имеет свои преимущества и ограничения.

Глубокое понимание математической модели, основанной на предположении яркостной сохранности, а также знание алгоритмических методов минимизации функционалов, позволяют создавать устойчивые и точные системы для решения широкого спектра прикладных задач.