


Лекция 7: Основы машинного обучения в компьютерном зрении

Компьютерное зрение с появлением машинного обучения и статистических методов позволило извлекать из изображений глубокую семантическую информацию. Это дало возможность создать системы, способные распознавать объекты, интерпретировать сцены и принимать решения в режиме реального времени. Машинное обучение является основой для построения таких систем, позволяя автоматически обучаться на примерах и обобщать полученные знания на новые данные.

и by Иван Копылов



Историческая справка и развитие подходов

1

1960-1970-е годы

Исследования сосредоточены на разработке алгоритмов для обработки сигналов и изображений при ограниченных вычислительных мощностях.

2

1980-1990-е годы

Появление классических алгоритмов: метод ближайших соседей (kNN), наивный байесовский классификатор, линейная дискриминантная функция и поддерживающие векторы (SVM).

3


Современность

Развитие вычислительной техники позволило применять более сложные алгоритмы, такие как ансамблевые методы и методы снижения размерности.

Computer Vision

and

Machine Learning



Geoffrey Hinton

Yann Lecun

Fei-Fei LI



Обзор задач и применений

Классификация изображений

Определение категории, к которой принадлежит изображение (например, распознавание рукописных цифр или классификация объектов на фотографии).

Детектирование объектов

Выделение и локализация объектов в изображении с последующей классификацией.


Сегментация изображений

Разбиение изображения на области с одинаковыми характеристиками для детального анализа.


Распознавание лиц и жестов

Идентификация или верификация людей по их лицам, а также анализ жестов для управления устройствами.

Dog



Person



Основные понятия машинного обучения

Классификация

Задача отнесения объекта (изображения, текста, сигнала) к одной из заранее определённых категорий. Пример – распознавание рукописных цифр.

Регрессия

Прогнозирование непрерывной величины на основе входных данных. Пример – оценка возраста человека по его фотографии.

Кластеризация

Группировка объектов по сходству без заранее известных меток классов. Пример – сегментация изображений для выделения объектов без знания их семантической значимости.

Обучение с учителем и без учителя

Обучение с учителем

Модели обучаются на размеченных данных, где каждому входному объекту соответствует известная метка. Такой подход позволяет оптимизировать функцию потерь, минимизируя ошибку между предсказанием и истинной меткой.

Обучение без учителя

Используется, когда данные не имеют меток. Задача модели – выявить скрытую структуру данных, например, путем кластеризации или снижения размерности.

Основные алгоритмы классического машинного обучения



k-Nearest Neighbors (kNN)

Алгоритм основан на поиске ближайших соседей в пространстве признаков. Решение принимается на основании большинства голосов среди k ближайших примеров.



Опорные векторы (SVM)

SVM ищет оптимальную разделяющую гиперплоскость, которая максимально разделяет классы в пространстве признаков.



Логистическая регрессия

Применяется для бинарной и многоклассовой классификации. Модель предсказывает вероятность принадлежности объекта к тому или иному классу с использованием логистической функции.



Деревья решений и ансамблевые методы

Деревья решений строят модель в виде иерархической структуры. Ансамблевые методы объединяют несколько деревьев для повышения устойчивости и точности модели.

Обзор гиперпараметров и их влияние

1

kNN

Основным параметром является число соседей (k) и выбор метрики расстояния.

2

SVM

Важны параметры регуляризации (C) и выбор ядра (линейное, полиномиальное, RBF и т.д.).

3

Логистическая регрессия

Роль играют коэффициенты регуляризации (например, L1 или L2 регуляризация).

4

Деревья решений

Важными являются максимальная глубина, минимальное число образцов в узле и критерии разделения (Gini, энтропия).

Что такое классификация изображений

Предобработка изображения

Изменение размера, нормализация, устранение шумов.

Извлечение признаков


Преобразование изображения в набор числовых характеристик, описывающих его содержимое.

Обучение модели

На основе извлечённых признаков и известных меток производится обучение алгоритма.

Оценка качества

Модель тестируется на отложенной выборке, а результаты оцениваются с использованием метрик.



Эволюция методов классификации



Современные тренды в классификации изображений

1

Низкая вычислительная сложность

Классические алгоритмы работают быстрее и требуют меньше памяти для небольших наборов данных и ограниченных вычислительных ресурсов.

2

Интерпретируемость

Модели, такие как SVM или решающие деревья, легче интерпретировать, что важно для прикладных задач, где требуется понимание причин принятия решения.


3

Комбинированные подходы

Гибридные модели, объединяющие классические алгоритмы и методы извлечения признаков, часто показывают конкурентоспособные результаты, особенно при ограниченном количестве размеченных данных.



Источники данных и их особенности




MNIST

Набор изображений рукописных цифр, состоящий из 70 000 изображений размером 28×28 пикселей. Отличная тестовая база для первичных экспериментов.



CIFAR-10 и CIFAR-100

Наборы данных с цветными изображениями различных классов (10 или 100 классов соответственно). Сложнее MNIST и требуют более тонкой настройки алгоритмов.



ImageNet

Огромный набор данных с миллионами изображений и тысячами классов. Применяется для обучения и оценки сложных моделей, в первую очередь в контексте глубокого обучения.

Предобработка изображений



Изменение размера (Resizing)

Приведение изображений к единому размеру позволяет унифицировать входные данные.



Нормализация

Приведение значений пикселей к определённому диапазону (например, $[0, 1]$ или $[-1, 1]$) способствует более стабильному обучению моделей.



Удаление шумов

Применение фильтров (например, гауссового размытия) для устранения мелких шумов, способных негативно влиять на извлечение признаков.



Центрирование

Корректировка яркости или контраста может повысить качество извлечённых признаков.

Извлечение признаков из изображений

Гистограмма ориентированных градиентов (HOG)

Метод вычисляет локальные гистограммы градиентов, что позволяет описать форму и контуры объектов. Основная идея состоит в разбиении изображения на небольшие клетки и вычислении гистограмм направлений градиентов для каждой клетки.

Локальные бинарные паттерны (LBP)

Метод основывается на сравнении значений яркости центрального пикселя с его соседями, что позволяет получить компактное описание текстурных особенностей изображения.

Метод «мешок визуальных слов» (Bag of Visual Words)

В этом подходе извлечённые локальные признаки (например, SIFT или SURF) группируются в кластеры, а затем каждому изображению сопоставляется гистограмма частоты встречаемости «визуальных слов».

Векторизация изображений и снижение размерности

Метод главных компонент (PCA)

Позволяет уменьшить размерность данных, сохраняя при этом наиболее значимые компоненты вариации.

Линейный дискриминантный анализ (LDA)

Помимо снижения размерности LDA также учитывает информацию о классах, что позволяет улучшить разделимость данных.

```
from sklearn.decomposition import PCA
import numpy as np
# Предположим, X - матрица признаков
pca = PCA(n_components=50)
X_reduced = pca.fit_transform(X)
```

Метод ближайших соседей (kNN)

Метод ближайших соседей является интуитивно понятным и простым алгоритмом, не требующим явного этапа обучения. Основная идея заключается в том, что для нового изображения ищутся k наиболее близких объектов в тренировочной выборке, а класс присваивается на основании большинства голосов.

```
from sklearn.neighbors import KNeighborsClassifier
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score


# Разделение данных на тренировочную и тестовую выборки
X_train, X_test, y_train, y_test = train_test_split(X_reduced, y, test_size=0.2, random_state=42)

# Инициализация и обучение модели kNN
knn = KNeighborsClassifier(n_neighbors=5)
knn.fit(X_train, y_train)

# Предсказание и оценка точности
y_pred = knn.predict(X_test)
print("Точность модели kNN:", accuracy_score(y_test, y_pred))
```

Опорные векторы (SVM)

Модель опорных векторов находит оптимальную гиперплоскость, разделяющую классы в пространстве признаков. Одним из ключевых преимуществ SVM является возможность применения ядерных методов, что позволяет моделям работать в нелинейно разделяемых пространствах.



```
from sklearn.svm import SVC
```


```
# Инициализация и обучение модели SVM  
svm = SVC(kernel='rbf', C=1.0, gamma='scale')  
svm.fit(X_train, y_train)
```

```
# Предсказание и оценка точности  
y_pred_svm = svm.predict(X_test)  
print("Точность модели SVM:", accuracy_score(y_test,  
y_pred_svm))
```


Логистическая регрессия

Логистическая регрессия применяется для задач бинарной классификации, а при расширении – для многоклассовых задач.

Модель предсказывает вероятность принадлежности объекта к тому или иному классу, что позволяет получать не только жесткие метки, но и оценки уверенности в решении.

**1**

Простота интерпретации

Коэффициенты модели легко интерпретировать, что важно для понимания влияния признаков.

2

Быстрая сходимость

При небольшом количестве признаков логистическая регрессия быстро сходится к оптимальному решению.

3

Возможность регуляризации

Применение L1 или L2 регуляризации помогает избежать переобучения модели.

Основные метрики оценки качества моделей



Accuracy (Точность)

Доля правильно предсказанных объектов ко всем объектам.



Precision (Точность по классу)

Доля истинно положительных предсказаний от общего числа объектов, предсказанных как положительные.



Recall (Полнота)


Доля истинно положительных предсказаний от общего числа реальных положительных объектов.



F1 Score

Гармоническое среднее между Precision и Recall, дающее баланс между ними.

Cross-Validation



Grid search

Кросс-валидация и подбор гиперпараметров

Для объективной оценки модели используется кросс-валидация, которая позволяет оценить устойчивость модели на разных подвыборках данных. Метод Grid Search позволяет систематически перебирать значения гиперпараметров для выбора оптимальной комбинации.

```
from sklearn.model_selection import GridSearchCV
```

```
param_grid = {  
    'C': [0.1, 1, 10],  
    'gamma': ['scale', 0.01, 0.001],  
    'kernel': ['rbf', 'linear']  
}
```

```
grid_search = GridSearchCV(SVC(), param_grid, cv=5)  
grid_search.fit(X_train, y_train)  
print("Лучшие параметры:", grid_search.best_params_)
```

Обзор современных подходов и их связь с классическими методами

1

Гибридные модели

Объединение классических методов с современными техниками, например, извлечение HOG-признаков с последующим использованием SVM для классификации.

2

Ансамблевые методы

Комбинирование нескольких моделей (например, SVM, kNN, логистической регрессии) для повышения стабильности и точности предсказаний.

3

Снижение размерности

Методы PCA и LDA помогают уменьшить размерность данных и улучшить разделимость классов, что особенно полезно при работе с большими наборами данных.

Тонкая настройка и подбор гиперпараметров

1

Grid Search

Перебор параметров по заданной сетке значений. Это позволяет систематически оценить комбинации, например, для SVM можно варьировать параметр регуляризации C и параметр ядра γ .

2

Random Search

Случайный перебор из распределения значений параметров. Данный метод часто быстрее, особенно при большом количестве гиперпараметров.

3


Bayesian Optimization

Использование вероятностной модели для поиска оптимальных значений, что позволяет быстрее сходиться к наилучшему набору параметров.

```
from sklearn.model_selection import GridSearchCV
from sklearn.svm import SVC

param_grid = {
    'C': [0.1, 1, 10, 100],
    'gamma': ['scale', 0.01, 0.001, 0.0001],
    'kernel': ['rbf', 'linear']
}

grid_search = GridSearchCV(SVC(), param_grid, cv=5, n_jobs=-1)
grid_search.fit(X_train, y_train)
print("Лучшие параметры:", grid_search.best_params_)
```



Алгоритмы оптимизации и методы обучения

1

Градиентный спуск (Gradient Descent)

Основной метод, где параметры модели обновляются согласно правилу: $\theta(t+1) = \theta(t) - \eta \nabla \theta L(\theta(t))$, где η — скорость обучения, а L — функция потерь.

2

Стохастический градиентный спуск (SGD)

Модификация, при которой обновление параметров производится для каждого примера или мини-батча, что значительно ускоряет обучение при больших выборках.

3

Методы с адаптивным шагом

Алгоритмы Adam, RMSProp, Adagrad адаптируют скорость обучения для каждого параметра индивидуально, что позволяет модели быстрее сходиться даже при сложном ландшафте функции потерь.

Регуляризация как способ борьбы с переобучением

L2 регуляризация (Ridge)

Добавляет штраф, пропорциональный квадрату нормы весов: $\min_{\theta} L(\theta) + \lambda \|\theta\|_2^2$, где λ — коэффициент регуляризации.

L1 регуляризация (Lasso)

Содействует разреженности параметров: $\min_{\theta} L(\theta) + \lambda \|\theta\|_1$.


Мотивация использования ансамблей

1 Bagging (Bootstrap Aggregating)

Построение нескольких моделей на различных бутстрэп-выборках из исходных данных. Классическим примером является случайный лес, где несколько деревьев решений обучаются на случайных подвыборках признаков и объектов.

2 Boosting

Последовательное обучение слабых моделей, каждая из которых исправляет ошибки предыдущей. Примеры — AdaBoost и Gradient Boosting, где итоговое предсказание получается как взвешенная сумма предсказаний всех моделей.



Случайный лес (Random Forest)

Случайный лес представляет собой ансамбль решающих деревьев, где каждая модель обучается на случайной подвыборке данных. Итоговое предсказание получается путём голосования всех деревьев.

```
from sklearn.ensemble import RandomForestClassifier

rf = RandomForestClassifier(n_estimators=100, max_depth=10,
random_state=42)
rf.fit(X_train, y_train)
y_pred_rf = rf.predict(X_test)
print("Точность модели Random Forest:", accuracy_score(y_test,
y_pred_rf))
```




Градиентный бустинг (Gradient Boosting)

Градиентный бустинг обучает последовательность моделей, каждая из которых направлена на уменьшение ошибки предыдущей. Итоговая модель строится как сумма слабых моделей, что позволяет достичь высокой точности.

```
from sklearn.ensemble import GradientBoostingClassifier
```

```
gb = GradientBoostingClassifier(n_estimators=200,  
learning_rate=0.1, max_depth=5, random_state=42)  
gb.fit(X_train, y_train)  
y_pred_gb = gb.predict(X_test)  
print("Точность модели Gradient Boosting:",  
accuracy_score(y_test, y_pred_gb))
```



Конвейер обработки данных

Сбор и разметка данных

Сбор изображений из различных источников и последующая разметка метками классов.

Предобработка

Изменение размеров, нормализация, фильтрация и коррекция изображений.

Извлечение признаков

Применение методов HOG, LBP, SIFT или «мешка визуальных слов» для преобразования изображений в векторы признаков.

Снижение размерности

Использование PCA или LDA для уменьшения размерности пространства признаков.

Обучение модели

Выбор и обучение подходящего алгоритма (kNN, SVM, логистическая регрессия и т.д.) с последующим подбором гиперпараметров.

Интерпретация результатов и анализ ошибок

Для понимания, какие классы наиболее проблемные для модели, применяется анализ матрицы ошибок (confusion matrix). Такой анализ позволяет выявить группы объектов, которые модель путает между собой.

```
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.metrics import confusion_matrix

cm = confusion_matrix(y_test, y_pred_rf)
plt.figure(figsize=(8,6))
sns.heatmap(cm, annot=True, fmt='d', cmap='viridis')
plt.xlabel("Предсказанный класс")
plt.ylabel("Истинный класс")
plt.title("Матрица ошибок для модели Random Forest")
plt.show()
```


		True Class		
		Apple	Orange	Mango
Predicted Class	Apple	7	8	9
	Orange	1	2	3
	Mango	3	2	1

Визуализация и интерпретация признаков

Помимо анализа ошибок, полезно визуализировать признаки, извлечённые из изображений. Например, можно отобразить распределение значений HOG-признаков или результаты снижения размерности с помощью методов t-SNE или PCA для наблюдения кластеризации объектов.

```
from sklearn.manifold import TSNE
import matplotlib.pyplot as plt

tsne = TSNE(n_components=2, random_state=42)
X_tsne = tsne.fit_transform(X_reduced)
plt.scatter(X_tsne[:, 0], X_tsne[:, 1], c=y, cmap='jet', s=5)
plt.colorbar()
plt.title("t-SNE визуализация признаков")
plt.show()
```



Обратная связь от модели

Для повышения интерпретируемости модели важно изучать вклад отдельных признаков в итоговое решение. Например, для SVM или логистической регрессии можно анализировать коэффициенты модели, чтобы понять, какие признаки наиболее значимы для классификации. Этот анализ помогает не только улучшить модель, но и выявить особенности данных, требующие дополнительной обработки.





Интеграция моделей в производственные системы

1 Реальное время

Оптимизация модели для работы в условиях ограниченных вычислительных ресурсов. Это может включать использование ускоренных библиотек (например, NumPy, Cython) и применение параллельных вычислений.

2 Масштабируемость

Возможность обработки больших потоков данных, таких как видеопоток с камер наблюдения, требует эффективной архитектуры конвейера обработки.

3 Обновляемость модели

При поступлении новых данных важно периодически переобучать модель или использовать методы онлайн-обучения, чтобы адаптироваться к изменяющейся среде.

Аппаратное ускорение в реальных системах

1 Параллельные вычисления

Использование многопоточных библиотек и GPU ускорителей позволяет сократить время обработки больших объёмов данных.

2 Оптимизированные библиотеки

Применение таких библиотек, как Intel MKL, OpenBLAS и других, обеспечивает быстрые операции с матрицами и векторами.

3 Модульное развертывание

Разбиение системы на модули (предобработка, извлечение признаков, классификация) позволяет оптимизировать каждый этап отдельно и обеспечить масштабируемость системы.



Гибридные системы: объединение традиционных и глубоких методов

Современные системы компьютерного зрения всё чаще используют гибридный подход, объединяя классические методы машинного обучения с глубокими нейронными сетями. Несмотря на то, что глубокое обучение продемонстрировало выдающиеся результаты во многих задачах, классические алгоритмы по-прежнему сохраняют преимущества в плане вычислительной эффективности и интерпретируемости.

```
# Извлечение HOG-признаков из изображения
from skimage.feature import hog
import cv2

image = cv2.imread("example.jpg")
gray = cv2.cvtColor(image, cv2.COLOR_BGR2GRAY)
fd, hog_image = hog(gray, orientations=9, pixels_per_cell=(8,8), cells_per_block=(2,2), visualize=True)

# Далее признаки можно объединить с извлечёнными признаками из сверточной нейронной сети
import numpy as np
cnn_features = extract_cnn_features(image) # Предположим, имеется функция для извлечения признаков CNN
hybrid_features = np.concatenate((fd, cnn_features))

# Использование гибридных признаков для классификации, например, с помощью SVM
from sklearn.svm import SVC
svm = SVC(kernel='rbf', C=1.0, gamma='scale')
svm.fit(hybrid_features_train, y_train)
y_pred = svm.predict(hybrid_features_test)
```

Передача обучения и адаптация домена

Для многих практических задач важна способность модели адаптироваться к данным, отличающимся от обучающего набора. Здесь в помощь приходит концепция transfer learning (переноса обучения) и адаптации домена.

```
import torch
import torch.nn as nn
from torchvision import models, transforms
from torch.utils.data import DataLoader, Dataset

# Загрузка предварительно обученной модели ResNet
model = models.resnet50(pretrained=True)

# Замораживаем все слои
for param in model.parameters():
    param.requires_grad = False

# Заменяем последний полносвязный слой для новой задачи
# (например, 10 классов)
num_features = model.fc.in_features
model.fc = nn.Linear(num_features, 10)

# Обучение только нового слоя на специфичных данных
criterion = nn.CrossEntropyLoss()
optimizer = torch.optim.Adam(model.fc.parameters(), lr=0.001)
```



Интерпретируемость и объяснимость моделей

1

Анализ весовых коэффициентов

Для линейных моделей, таких как логистическая регрессия или линейные SVM, коэффициенты позволяют оценить значимость каждого признака.

2

Методы визуализации

Техники, такие как t-SNE или PCA, позволяют отобразить распределение признаков и выявить кластеры объектов.

3

Методы объяснимости

Например, LIME (Local Interpretable Model-agnostic Explanations) позволяет локально интерпретировать предсказания модели, выделяя важные для решения признаки.

```
import lime
from lime import lime_image
import numpy as np

explainer = lime_image.LimeImageExplainer()
explanation = explainer.explain_instance(image, classifier_fn, top_labels=5, hide_color=0, num_samples=1000)
temp, mask = explanation.get_image_and_mask(explanation.top_labels[0], positive_only=True, num_features=10,
hide_rest=False)
plt.imshow(mark_boundaries(temp / 255.0, mask))
plt.title("Объяснение предсказания с помощью LIME")
plt.show()
```

Практические кейсы в медицинской диагностике



В медицине системы компьютерного зрения применяются для диагностики заболеваний на основе анализа изображений:

1 Рентген и МРТ

Классические методы, такие как SVM или ансамблевые модели, помогают обнаруживать аномалии в изображениях легких, костей или мягких тканей.

2 Ультразвуковая диагностика

Извлечение признаков из изображений ультразвука и последующая классификация позволяют выявлять патологии в режиме реального времени.



Контроль качества на производстве


В промышленности модели компьютерного зрения используются для автоматического контроля качества продукции:

1 Обнаружение дефектов

Изображения изделий анализируются для выявления царапин, трещин и других дефектов. Классические методы в сочетании с методами сегментации позволяют локализовать и классифицировать дефекты.

2 Реальное время

Оптимизированные конвейеры обработки данных позволяют выполнять анализ на лету, что важно для автоматизированных производственных линий.



Системы безопасности и видеонаблюдение


В системах безопасности ключевым элементом является распознавание лиц и объектов:


1 Распознавание лиц

Комбинация классических методов для извлечения признаков (например, LBP) и моделей классификации позволяет достигать высокой точности даже при различных условиях освещения.

2 Анализ видеопотока

Использование ансамблевых моделей помогает отслеживать перемещения объектов и обнаруживать подозрительную активность в режиме реального времени.





Анализ спортивных данных

Компьютерное зрение активно применяется в спорте для анализа техники спортсменов, отслеживания траекторий движения и определения стратегических решений:

1

Классификация поз

Изображения или видео спортсменов анализируются для распознавания поз и движений, что позволяет проводить детальный анализ техники.

2

Анализ тактики

Системы, основанные на извлечении признаков и последующей классификации, помогают тренерам и аналитикам оценивать эффективность различных игровых стратегий.

Перспективы и направления будущих исследований

1

Развитие гибридных моделей

Создание моделей, которые не только дают высокую точность, но и позволяют понять вклад отдельных признаков в итоговое решение.

2

Улучшение адаптации к новым доменам

Разработка методов, позволяющих модели эффективно адаптироваться к изменениям в освещенности, качестве изображения или типу объектов.

3

Применение методов объяснимости

Интеграция методов LIME, SHAP и Grad-CAM для локальной интерпретации решений модели и выявления ключевых признаков, влияющих на предсказание.

4


Оптимизация вычислительных ресурсов

Разработка энергоэффективных моделей, обеспечивающих высокую точность при минимальных вычислительных затратах.



Рекомендации и заключения

- 1 Экспериментировать с гибридными подходами**
Совмещайте классические методы извлечения признаков с современными техниками глубокого обучения для повышения интерпретируемости и точности моделей.
- 2 Применять методы адаптации домена и переноса обучения**
Используйте предварительно обученные модели и адаптируйте их к специфическим условиям ваших данных, что позволит существенно сократить время обучения и повысить стабильность решений.
- 3 Оптимизировать вычислительные процессы**
Инвестируйте усилия в разработку энергоэффективных и масштабируемых алгоритмов, особенно для систем, работающих в режиме реального времени или на мобильных устройствах.
- 4 Сосредоточиться на объяснимости**
Разрабатывайте и внедряйте методы, позволяющие понимать и интерпретировать работу модели, что особенно важно в критически важных приложениях.



Ссылки на дополнительную литературу и ресурсы

1 Книги

- Pattern Recognition and Machine Learning — Christopher Bishop
- The Elements of Statistical Learning — Hastie, Tibshirani, Friedman
- Deep Learning — Ian Goodfellow, Yoshua Bengio, Aaron Courville

2 Научные статьи

Классические публикации по методам SVM, ансамблевым моделям и техникам адаптации домена. Современные исследования по методам объяснимости и гибридным системам в компьютерном зрении.

3 Онлайн-курсы и ресурсы

Образовательные платформы Coursera и edX, предлагающие курсы по машинному обучению и компьютерному зрению. Документация и учебные материалы для библиотек TensorFlow, PyTorch, scikit-learn и OpenCV.

